



llama-3.1-8b





NotInject

não se aplica

*O NotInject é só-benigno:
não há ataque, logo não há
denominador para o ASR*



gpt-oss-20b



não se aplica

*O NotInject é só-benigno:
não há ataque, logo não há
denominador para o ASR*

gpt-oss-safeguard (filtro)
+ gpt-oss-20b



não se aplica

*O NotInject é só-benigno:
não há ataque, logo não há
denominador para o ASR*